La realidad de la lectura en México: perfiles lectores y su evolución (MOLEC 2019–2024)

Reporte final

Equipo 5

Vicente Alonso Gallardo Montalva – A01787981

Jia-Hong André Kuo Ko – A01179116

Mauricio Ruiz Junco – A01783698

Mauricio Horcasitas Farah – A00843564

24/10/2026

Modelación estadística para la toma de decisiones (Gpo 202)

Dra. Blanca R. Ruiz Hernández, Dra. María Guadalupe Tobías Lara

Resumen

Problemática. Entre 2015 y 2024 la población urbana alfabeta de México que leyó algún material bajó de 84.2% a 69.6% (INEGI, 2024), pero los promedios no dicen quién dejó de leer ni qué lee. Este trabajo pregunta cómo cambió el comportamiento lector entre 2019 y 2024, qué arquetipos de lector pueden identificarse y qué estrategias de fomento se desprenden de ellos.

Método. Se integraron los microdatos del Módulo sobre Lectura (MOLEC) del INEGI de 2019 a 2024: 11,685 personas alfabetas de 18 años y más en ciudades de 100 mil habitantes o más. Los porcentajes se ponderaron con el factor de expansión y su incertidumbre se ajustó con el tamaño efectivo de muestra. Con un nivel de significancia de 0.04 se construyeron intervalos de confianza para proporciones, medias y el cociente de varianzas, y seis pruebas de hipótesis: tres de diferencia de proporciones, un ANOVA (confirmado con Welch), una prueba de Kruskal–Wallis y una χ^2 de independencia con corrección de Rao–Scott. Como exploración complementaria se identificaron arquetipos de lector con *k-means*, con conjuntos de entrenamiento, validación y prueba.

Resultados. Con 96% de confianza, la no lectura aumentó entre 1.8 y 8.6 puntos (de 25.2% a 30.4%) y la lectura de periódicos cayó entre 12.9 y 19.4 puntos, mientras que no hay evidencia de cambio en la lectura de libros ni de internet. El aumento de la no lectura es claro entre personas con secundaria y media superior. Entre los lectores de libros, la mediana pasa de 1 libro al año con primaria o menos a 3 con educación superior, y lee libros 53.2% de quienes tuvieron libros en casa durante la infancia, frente a 26.0% de quienes no los tuvieron. *K-means* propone seis arquetipos (no lectores y lectores de periódicos, de internet, de impresos, de libros digitales y de historietas) que la edad y la escolaridad explican solo en parte.

Conclusiones. El fomento de la lectura que motivó la creación de MOLEC no ha frenado la no lectura. Se propone dirigir las acciones según qué y cómo lee cada arquetipo, y no solo según la demografía, con dos líneas transversales: llevar libros a los hogares con niños y medir cada año el peso de cada arquetipo. Al tratarse de datos observacionales, los resultados son asociaciones, no causas.

1. Introducción y justificación

Leer es la base de otras habilidades. En un metaanálisis de 99 estudios, Mol y Bus (2011) encontraron una relación de moderada a fuerte entre la lectura en el tiempo libre y la comprensión lectora, desde preescolar hasta la universidad: quien comprende mejor lee más y, al leer más, comprende mejor, una "espiral" que también funciona en sentido contrario. Fernández Martínez (2025) vincula la baja comprensión lectora con una mayor vulnerabilidad ante la desinformación y con el abandono escolar, por lo que medir la lectura es de interés público: sin datos no se puede saber si las políticas de fomento funcionan ni a quién dirigirlas.

El panorama es preocupante. La pandemia elevó de 483 a 584 millones el número de niñas y niños sin habilidades mínimas de lectura (UNESCO, 2021), y en PISA 2025 México obtuvo 408 puntos en lectura, frente a 461 del promedio de la OCDE (OECD, 2026). En adultos, el Módulo sobre Lectura (MOLEC) del INEGI, cuyo objetivo es "generar información estadística sobre el comportamiento lector [...] y proporcionar elementos para el fomento de la lectura" (INEGI, 2024), muestra que la población alfabeta urbana que leyó algún material bajó de 84.2% en 2015 a 69.6% en 2024. Fernández Martínez (2025) atribuye la caída a la competencia del celular y las redes sociales y a políticas diseñadas sin evidencia, como la ley de precio único del libro.

Medir la lectura también tiene límites. MOLEC se basa en el autorreporte, solo representó a la población urbana hasta 2024 y en 2025 cambió su cuestionario, lo que "genera una nueva serie de información" (INEGI, 2025); leer en pantalla tampoco equivale a leer en papel (Delgado et al., 2018), y al tratarse de datos observacionales, correlación no implica causalidad. MOLEC ha cumplido su objetivo de generar información, pero la caída sostenida indica que el fomento no ha revertido la tendencia. Para que iniciativas como Pasión por la lectura del Tecnológico de Monterrey (s. f.) lleguen a quien más las necesita, hace

falta saber qué tipos de lectores y no lectores existen y cómo están cambiando.

1.1 Pregunta de investigación

¿Cómo cambió el comportamiento lector de la población urbana alfabeta de 18 años y más entre 2019 y 2024, según MOLEC, qué arquetipos de lector pueden identificarse y qué estrategias de fomento se desprenden de ellos?

La pregunta original buscaba perfiles de lector y su evolución. A partir de la retroalimentación de las etapas anteriores se ajustó en dos sentidos: la inferencia se hace ahora sobre indicadores y grupos definidos antes de las pruebas (por ejemplo, la proporción que leyó libros en 2019 y en 2024), y los perfiles obtenidos con *k-means* se usan como exploración para proponer estrategias, no como objeto de prueba. Los objetivos específicos son:

1. **Estimar y probar** si entre 2019 y 2024 cambió la proporción de personas que no leen, que leen libros, periódicos o internet, también dentro de cada nivel de escolaridad.
2. **Comparar** cuántos libros leen los lectores según su escolaridad y si leer libros se asocia con haber tenido libros en casa durante la infancia.
3. **Explorar** arquetipos de lector con *k-means* (entrenamiento, validación y prueba) y caracterizarlos.
4. **Proponer** una estrategia de fomento basada en los arquetipos.

MOLEC es una serie de cortes transversales: cada año se entrevista a personas distintas. Por ello, los cambios se entienden como cambios en la población representada, no como el tránsito de una misma persona entre categorías.

1.2 Justificación

Los indicadores que publica INEGI son promedios, y un promedio estable puede ocultar cambios en la composición de la población (Fernández Martínez, 2025). Entre 2019 y 2024 el porcentaje ponderado que leyó libros pasó de 42.2% a 41.8%, prácticamente sin cambio, pero la lectura de revistas bajó de 34.3% a 21.7%, la de periódicos de 34.0% a 17.8% y la no lectura subió de 25.2% a 30.4% (Figura 1). Identificar perfiles permite dirigir el fomento a públicos concretos y relacionarlos con las dos áreas de oportunidad que señalan las fuentes: el hogar y la escuela.

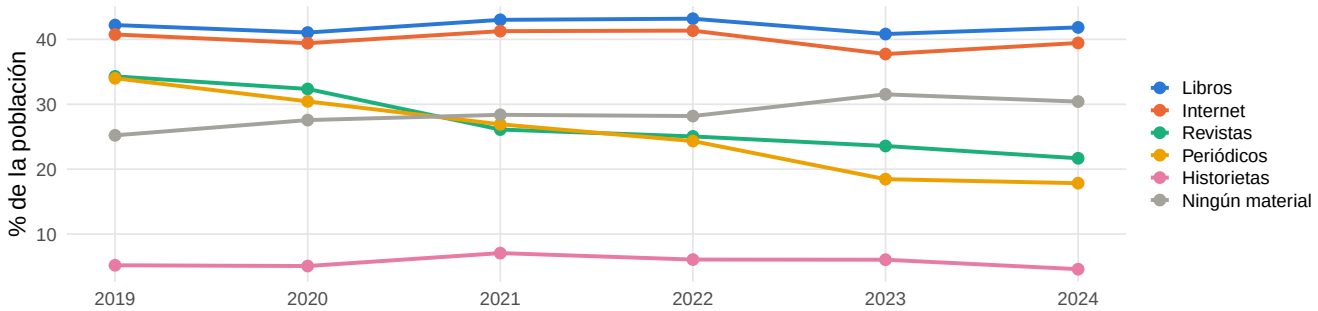


Figura 1: Porcentaje ponderado de la población alfabeta de 18 años y más que leyó cada material, MOLEC 2019–2024.

2. Metodología

2.1 Fuente de datos, población y muestra

Los datos provienen del Módulo sobre Lectura (MOLEC) del INEGI (2019–2025), que hasta 2024 se levantó cada febrero en 32 ciudades de 100 mil habitantes o más, una por entidad federativa (INEGI, 2025). En cada vivienda seleccionada se entrevista a una sola persona de 18 años o más. El muestreo es probabilístico, estratificado y por conglomerados, y cada persona tiene un factor de expansión que indica a cuántas personas de la población representa. La población objetivo es la población urbana alfabeta de

18 años y más.

Estructura. Se integraron los seis levantamientos de MOLEC 2019–2024: 11,966 registros con 108 columnas por año, en los que cada registro es **una persona** de 18 años o más seleccionada en una vivienda. Las variables seleccionadas tienen la misma redacción y codificación en los seis años (1 Sí, 2 No, 3 No recuerda, 0 = blanco por pase); solo se homologaron algunos nombres de columna (por ejemplo, `n_ren_ele` y `P36_1` en 2019). Se excluye 2025 porque su cuestionario se rediseñó: incluye a 428 personas de 12 a 17 años, amplía la definición de "libro" y no trae factor de expansión. Como verificación, los porcentajes ponderados reproducen las cifras oficiales de 2024. Se analiza la población **alfabeta** (`p1 = 1`), la única a la que se aplica el módulo.

2.2 Cómo se aborda la pregunta

La pregunta de investigación se descompone en tres preguntas secundarias: (1) ¿cambió entre 2019 y 2024 la proporción de personas que no leen, que leen libros, periódicos o internet, también dentro de cada nivel de escolaridad?; (2) ¿a quién conviene dirigir el fomento, es decir, la cantidad de libros que se leen y la lectura de libros dependen de la escolaridad y de haber tenido libros en casa?, y (3) ¿qué arquetipos de lector pueden identificarse a partir del comportamiento lector? Las dos primeras se responden con inferencia estadística sobre grupos definidos de antemano y la tercera, con *k-means* como exploración.

2.3 Variables y limpieza de datos

Variables. Se seleccionaron 25 variables de MOLEC: las de **agrupamiento** describen el comportamiento lector (si lee cada material, cuántos libros, revistas y periódicos, minutos por sesión, si acostumbra leer y si lee libros digitales) y son las que usa *k-means*; las de **validación** (edad, escolaridad, sexo, entidad y ocho antecedentes de lectura en la infancia y la primaria) no entran al algoritmo; sirven para caracterizar a los arquetipos y para definir los grupos de las pruebas inferenciales. A ellas se agregaron siete atributos derivados (tipo de lector de INEGI, número de materiales, grupo de edad, escolaridad agrupada, índices de estímulos en el hogar y en la primaria, y la partición). El **Anexo A** describe las 32 variables (descripción, tipo, valores y faltantes).

Calidad. Las únicas celdas vacías son 60 valores de `mat_lec` en 2019, todos de personas que no saben leer. Los pases de pregunta se codifican como 0, así que cada código especial se revisó en el diccionario antes de decidir qué hacer con él (Tabla 8, Anexo A). No hay valores fuera del rango del diccionario ni registros duplicados (0 claves de persona repetidas y 0 filas idénticas).

Respecto a la Etapa 1 se corrigieron tres decisiones: el 99 de los conteos se conserva, los pases de `p26` y `p8_1` se tratan como "no aplica" en lugar de cero, y ya no se eliminan los registros con algún "No recuerda". Este último cambio es el más importante: `na.omit()` descartaba 1,409 personas (12.1%), de mayor edad (51.5 frente a 44.4 años) y menos lectoras (61.5% frente a 72.7%), lo que sesgaba la base. Ahora cada faltante se excluye solo del análisis de su variable, y la base preparada (`BasePreparada_MOLEC_2019_2024.csv`) tiene 11,685 registros.

2.4 Técnicas estadísticas y nivel de significancia

Siguiendo la retroalimentación recibida, la inferencia se hace sobre **indicadores y grupos definidos antes de las pruebas**, y no sobre los grupos de *k-means*. Como los grupos de *k-means* se construyen buscando patrones en los mismos datos, probar después diferencias entre ellos puede producir significancias engañosas; por eso el agrupamiento se reporta aparte como exploración (secciones 2.5 y 3.4). La Tabla 1 relaciona cada pregunta con su técnica. Todas las pruebas usan $\alpha = 0.04$ y todos los intervalos, una confianza de 96%.

Tabla 1: Preguntas inferenciales, población, técnica y distribución muestral.

Pregunta	Población y grupos	Técnica	Distribución
¿Qué proporción no leyó, leyó libros, periódicos o internet en 2019 y 2024?	Población alfabeta, cada año	IC de una proporción	Normal (Z)
¿Cuánto cambió cada proporción?	2019 frente a 2024	IC de la diferencia de proporciones	Normal (Z)
¿Aumentó la no lectura? ¿Cambió la lectura de libros? ¿Bajó la de periódicos?	2019 frente a 2024	Pruebas de diferencia de proporciones	Normal (Z)
¿Aumentó la no lectura dentro de cada nivel de escolaridad?	Cuatro niveles de escolaridad	IC de la diferencia de proporciones	Normal (Z)
¿Cuántos libros leen los lectores de cada nivel?	Lectores de libros, por escolaridad	IC de la media; IC del cociente de varianzas	t; F
¿Difiere la cantidad de libros entre niveles?	Lectores de libros, por escolaridad	ANOVA (y Welch); Kruskal–Wallis	F; chi cuadrada
¿Se asocia leer libros con haber tenido libros en casa?	Población alfabeta	Prueba de independencia (Rao–Scott)	Chi cuadrada

Diseño muestral. MOLEC tiene un diseño estratificado y por conglomerados, y el factor de expansión pondera a cada persona. Las proporciones se estiman con el factor de expansión y, para su incertidumbre, se usa el **tamaño efectivo de muestra** de Kish (1965), $n_{ef} = (\sum w)^2 / \sum w^2$, que reduce el tamaño de la muestra según la variabilidad de los pesos: el efecto de diseño por ponderación va de 1.29 a 1.35 según el año, es decir, cada año la muestra "vale" como una de unas 1,455 a 1,511 personas. En la prueba χ^2 el estadístico se divide entre el efecto de diseño (corrección de primer orden de Rao y Scott, 1984). Esta corrección no incorpora los conglomerados, así que los intervalos siguen siendo una aproximación algo optimista. Cada año es una muestra independiente y se selecciona una sola persona por vivienda.

Aproximación normal. Una proporción muestral es el promedio de una variable que vale 1 o 0, así que, por el teorema del límite central, su distribución se aproxima a la normal cuando la muestra es grande; la regla usual es que $n\hat{p}$ y $n(1-\hat{p})$ sean al menos 5. Con el tamaño efectivo, el menor de esos valores en los intervalos por año es 265.4 y, dentro de los niveles de escolaridad, 34.7, así que la aproximación es válida (Anexo C).

Por qué estas pruebas. Cada prueba responde una parte de la pregunta de investigación:

- *Pruebas 1 a 3 (diferencia de proporciones, distribución normal).* Responden cómo cambió la lectura. Cada indicador es de sí o no y 2019 y 2024 son muestras independientes, así que se comparan dos proporciones. La no lectura (prueba 1) es el indicador central que MOLEC se creó para medir; la lectura de libros (prueba 2) indica si el cambio ocurre en el núcleo de lectores de libros, y la de periódicos (prueba 3) confirma el cambio de formato. Las pruebas 1 y 3 son de una cola porque el análisis descriptivo y la literatura anticipaban una dirección (más no lectura, menos periódicos); la 2 es de dos colas porque no había una dirección esperada.
- *Pruebas 4 y 5 (ANOVA y Kruskal–Wallis).* Responden a quién dirigir el fomento: si, entre quienes leen libros, la cantidad depende de la escolaridad. El ANOVA compara las medias de $\log(1+\text{libros})$ de los cuatro niveles en una sola prueba, sin inflar el error como lo harían varias pruebas *t*. Su supuesto de normalidad se refiere a las medias de cada grupo: con 500 a 2,266 lectores por nivel, el teorema del límite central las hace aproximadamente normales, aunque la prueba de Shapiro–Wilk, muy sensible con muestras de este tamaño, rechace la normalidad de los datos. Como las varianzas no son iguales, el resultado se confirma con el ANOVA de Welch, y la prueba de Kruskal–Wallis, que no requiere normalidad y compara medianas, verifica que la conclusión no dependa de ese supuesto.
- *Prueba 6 (independencia, χ^2 con Rao–Scott).* Sostiene la línea del hogar de la estrategia: relaciona dos variables categóricas, leer libros y haber tenido libros en casa durante la infancia, y la corrección de Rao–Scott ajusta el estadístico por el diseño muestral.

2.5 Arquetipos de lector con *k-means*

Entrenamiento, validación y prueba. La base se dividió al azar en tres subconjuntos ajenos (70/15/15 %, estratificados por año). Con el de **entrenamiento** (8,179 registros) se *ajusta* el modelo: *k-means* calcula ahí los centroides y la estandarización. El de **validación** (1,753) no interviene en el ajuste; sirve para *elegir* entre alternativas, como el número de grupos. El de **prueba** (1,753) se reserva y se usa una sola vez para evaluar el modelo elegido con datos que nunca vio; si se usara para decidir, la evaluación dejaría de ser honesta (Hastie et al., 2009). Esta división es distinta de la caracterización de los arquetipos con variables que no se usaron para formarlos (edad, escolaridad, antecedentes). Los tres subconjuntos son semejantes (no lectores: 28.6%, 28.0% y 29.3%; edad media: 45.2, 45.1 y 45.4 años).

Propósito y alcance. *K-means* se usa aquí como herramienta exploratoria para proponer arquetipos de lector que sirvan para diseñar estrategias, no como prueba de que esos grupos "existen". Por eso no se hace inferencia sobre los arquetipos: sus pesos por año se reportan de forma descriptiva, ponderados con el factor de expansión.

Variables y valores "no aplica". Se usaron ocho variables de comportamiento: los conteos de libros, revistas y periódicos y los minutos de lectura, transformados con $\log(1 + x)$ por su asimetría, y cuatro indicadores (lee internet, lee historietas, lee libros digitales y acostumbra leer). *K-means* necesita un valor numérico para todas las personas, así que los dos "no aplica" se trataron de forma explícita: **los minutos de lectura de quien no lee ningún material se fijaron en 0**, porque no dedica tiempo a leer, y **la lectura digital de quien no leyó libros se fijó en 0** ("no lee libros digitales"). Se descartó eliminar a esas personas, porque se perdería al 29.5% de la muestra, que no lee nada, y se descartó imputar la media, porque inventaría un comportamiento que no existe. La consecuencia es que los no lectores forman su propio grupo. Las variables se estandarizaron con el conjunto de entrenamiento.

Número de arquetipos. Se eligió con el conjunto de validación (Figura 13, Anexo C). La **silueta** mide qué tan separado está cada grupo de los demás (Rousseeuw, 1987), y la **estabilidad** (índice de Rand ajustado; Hubert y Arabie, 1985) compara la asignación de la validación a los centroides del entrenamiento con un *k-means* hecho solo con la validación. La estabilidad cae de 0.97 con 6 grupos a 0.71 con 7, así que se eligieron **6 arquetipos**. En el conjunto de prueba, usado una sola vez, la silueta fue de 0.45 y la estabilidad de 0.97: los arquetipos se reproducen en datos que el modelo no vio.

3. Resultados

3.1 Análisis descriptivo

Los porcentajes de esta sección se ponderan con el factor de expansión para representar a la población de cada año; las medidas de las variables numéricas describen la muestra.

Variables numéricas. La edad es casi simétrica (media de 45.2 y mediana de 44 años; sesgo de 0.3). Los conteos de lectura, en cambio, tienen una fuerte asimetría a la derecha (Tabla 2): entre quienes leyeron libros, la mediana es de 2 y la mitad central leyó entre 1 y 4 libros, pero la media sube a 3.5 (sesgo de 7.3, curtosis de 75.2) y 307 personas (6.3%) leyeron más de 8.5 libros. Son valores válidos de lectores intensivos y se conservan. Los minutos se comportan igual (mediana de 30 y media de 40.6). Por eso las comparaciones descriptivas usan medianas y, en *k-means*, los conteos se transforman con $\log(1 + x)$ (secciones 2.5 y 3.3). Los histogramas están en el Anexo B.

Tabla 2: Medidas descriptivas de las variables numéricas (muestra sin ponderar).

	n	Media	Mediana	Rango medio	DE	CV (%)	Q1	Q3	Mín.	Máx.	Sesgo	Curtosis
Edad (años)	11,685	45.24	44	57.5	16.48	36.42	31	57	18	97	0.33	-0.72
Libros en 12 meses*	4,868	3.53	2	50.0	5.40	153.00	1	4	1	99	7.29	75.20
Revistas en 3 meses*	3,119	3.62	3	50.0	5.19	143.26	2	4	1	99	9.84	133.57
Periódicos la semana pasada*	2,941	3.37	3	40.5	3.78	112.37	1	5	1	80	9.69	145.60
Minutos continuos de lectura*	8,243	40.57	30	240.5	33.87	83.50	20	60	1	480	3.40	21.72
Materiales leídos (0–5)	11,685	1.36	1	2.5	1.20	88.02	0	2	0	5	0.62	-0.31

* Solo quienes leyeron ese material (minutos: quienes leen algún material). Curtosis en exceso (0 = normal).

Variables categóricas. En la población representada, 28.6% no leyó ningún material, 29.4% leyó otros materiales pero no libros, 9.7% leyó solo libros y 32.4%, libros y otros materiales; los libros (42.0%) y el internet (40.0%) son lo más leído. La categoría mediana es media superior en escolaridad y de 30 a 44 años en edad, y 27.7% no tuvo ningún estímulo a la lectura en el hogar durante la infancia. Las distribuciones completas, los antecedentes por separado y la no lectura por entidad (de 7.5% a 42.3%) están en el Anexo B.

Comparaciones. Entre 2019 y 2024 la no lectura subió de 25.2% a 30.4% y quienes leen *solo* libros pasaron de 7.1% a 12.2%, mientras que bajaron quienes leen varios materiales; la lectura de libros digitales saltó de 17.0% en 2020 a 27.1% en 2021 y se mantuvo. La no lectura aumentó dentro de los cuatro niveles de escolaridad, sobre todo con secundaria (de 33.2% a 45.0%), aunque la población de 2024 tiene más escolaridad. Entre los lectores de libros, la mediana pasa de 1 libro con primaria o menos a 3 con educación superior (Anexo B). Los contrastes más marcados (Figura 4, Anexo B) son estos: la no lectura va de 52.7% con primaria o menos a 11.0% con educación superior, y de 50.8% sin estímulos en el hogar a 9.9% con los cuatro; haber tenido libros en casa se asocia con más lectura de libros incluso dentro de cada nivel educativo (de 20.3% a 34.3% con primaria o menos). Por último, las variables de lectura están poco correlacionadas entre sí (Spearman: libros y revistas, $\rho = 0.01$; libros y minutos, $\rho = 0.45$), lo que justifica buscar perfiles con varias dimensiones.

Estos resultados motivan las preguntas secundarias planteadas en la sección 2.2, que se responden a continuación con inferencia sobre grupos definidos de antemano.

3.2 ¿Cambió la lectura entre 2019 y 2024?

Intervalos de confianza. Para cada indicador se construyó un intervalo de una proporción, $\hat{p} \pm z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})/n_{ef}}$, con $z_{0.02} = 2.05$, y uno para la diferencia $p_{2024} - p_{2019}$ con el error estándar $\sqrt{\hat{p}_1\hat{q}_1/n_{ef,1} + \hat{p}_2\hat{q}_2/n_{ef,2}}$ (Tabla 3). Con 96% de confianza, la no lectura aumentó entre 1.8 y 8.6 puntos y la lectura de periódicos cayó entre 12.9 y 19.4 puntos. En cambio, los intervalos de la lectura de libros y de internet incluyen el cero, así que no hay evidencia de que hayan cambiado.

Tabla 3: Intervalos de confianza al 96% para la proporción ponderada de cada indicador en 2019 y 2024 y para su diferencia (normal, con tamaño efectivo).

Indicador	2019: % [IC 96%]	2024: % [IC 96%]	Diferencia (puntos) [IC 96%]	¿Incluye 0?
No leyó ningún material	25.2 [22.9, 27.5]	30.4 [28.0, 32.9]	5.2 [1.8, 8.6]	No
Leyó libros	42.2 [39.6, 44.8]	41.8 [39.2, 44.5]	-0.4 [-4.1, 3.4]	Sí
Leyó periódicos	34.0 [31.5, 36.5]	17.8 [15.8, 19.9]	-16.2 [-19.4, -12.9]	No
Lee internet	40.8 [38.1, 43.4]	39.4 [36.8, 42.0]	-1.3 [-5.0, 2.4]	Sí

Pruebas 1 a 3: diferencia de proporciones. El estadístico $z = (\hat{p}_{2024} - \hat{p}_{2019})/\sqrt{\bar{p}(1-\bar{p})(1/n_{ef,1} + 1/n_{ef,2})}$, con la proporción combinada $\bar{p}$, sigue una distribución normal estándar.

- *Prueba 1 (no lectura).* H_0: $p_{2024} \leq p_{2019}$; H_1: $p_{2024} > p_{2019}$. Se obtuvo $z = 3.16$, mayor que el valor crítico de una cola $z_{0.04} = 1.75$ (valor $p < 0.001$): se rechaza H_0 y se concluye que la no lectura aumentó.
- *Prueba 2 (libros).* H_0: $p_{2024} = p_{2019}$; H_1: $p_{2024} \neq p_{2019}$. Se obtuvo $z =$ -0.20, dentro de la región de no rechazo (entre -2.05 y 2.05; valor $p = 0.8409$): no hay evidencia de que la proporción que lee libros haya cambiado.
- *Prueba 3 (periódicos).* H_0: $p_{2024} \geq p_{2019}$; H_1: $p_{2024} < p_{2019}$. Se obtuvo $z =$ -10.06, menor que $-z_{0.04}$ = -1.75 (valor $p < 0.001$): se rechaza H_0.

No lectura dentro de cada nivel de escolaridad. La Figura 2 (b) muestra los intervalos de la diferencia de la no lectura entre 2019 y 2024 dentro de cada nivel. El aumento es claro con secundaria (entre 4.3 y 19.2 puntos) y con media superior (entre 1.5 y 13.5); con primaria o menos y con educación

superior el intervalo incluye el cero, en parte porque esos grupos son más pequeños o tienen proporciones extremas. Así, el aumento de la no lectura no se explica por un cambio en la escolaridad de la población: ocurre al menos en los niveles intermedios.

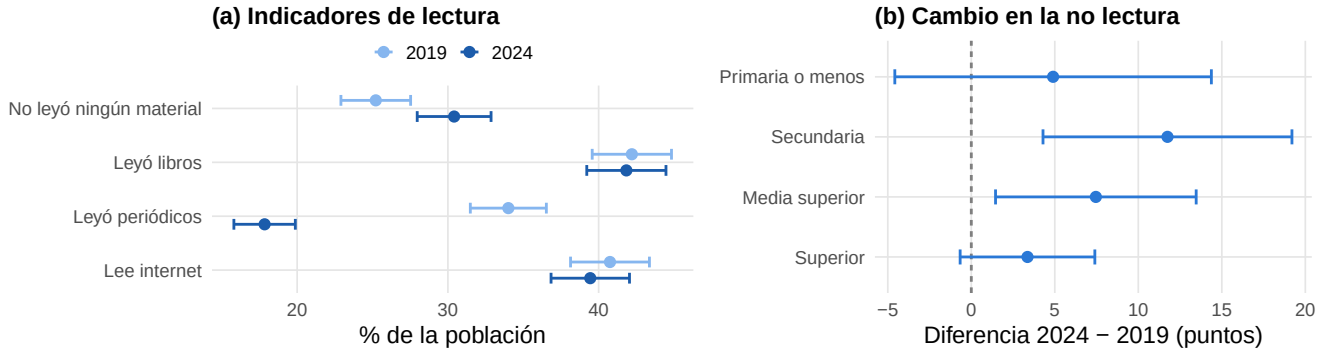


Figura 2: Intervalos de confianza al 96% (normal, con tamaño efectivo): (a) proporción de cada indicador en 2019 y 2024; (b) diferencia 2024 - 2019 de la no lectura dentro de cada nivel de escolaridad. La línea vertical de (b) marca el cero.

3.3 ¿A quién dirigir el fomento? Escolaridad y hogar

Entre quienes leyeron libros, el conteo es muy asimétrico (sección 3.1), así que se analiza $\log(1 + \text{libros})$, cuya distribución es mucho menos asimétrica (Anexo C). Los intervalos t de la media del logaritmo, regresados a la escala original, dan una "media geométrica" de 1.7 libros con primaria o menos [1.6, 1.9] y de 3.1 con educación superior [3.0, 3.2]; los intervalos de los cuatro niveles no se traslapan. Para revisar la igualdad de varianzas se construyó un intervalo para el cociente entre la varianza mayor (superior) y la menor (primaria o menos), con la distribución F de (2,265, 499) grados de libertad: $\sigma_1^2/\sigma_2^2 \in [1.27, 1.69]$. Como no incluye el 1, las varianzas difieren, igual que indica la prueba de Levene (valor $p < 0.001$).

Prueba 4: ANOVA. H_0: las medias de $\log(1 + \text{libros})$ son iguales en los cuatro niveles; H_1: al menos una difiere. El estadístico F sigue una distribución F con (3, 4,860) grados de libertad. Se obtuvo $F = 92.6$, mayor que el valor crítico $F_{0.04} = 2.77$ (valor $p < 0.001$), así que se rechaza H_0. Supuestos: la prueba de Shapiro–Wilk rechaza la normalidad en los cuatro niveles (Anexo C), algo esperable con muestras grandes y un conteo discreto, pero con 500 o más lectores por nivel el teorema del límite central hace que las medias muestrales sean aproximadamente normales, y el ANOVA es robusto a esa desviación. La varianza no es homogénea, por lo que el resultado se confirmó con el ANOVA de Welch, que no la supone ($F = 98.1$, valor $p < 0.001$).

Prueba 5: Kruskal–Wallis. Como alternativa no paramétrica, que no requiere normalidad, se compararon las medianas del número de libros: H_0: la mediana es igual en los cuatro niveles; H_1: al menos una difiere (interpretación válida porque las distribuciones de los niveles tienen forma parecida). El estadístico H sigue aproximadamente una distribución χ^2 con 3 grados de libertad. Se obtuvo $H = 349.2$, mayor que el valor crítico 8.31 (valor $p < 0.001$): las medianas difieren, de 1 libro con primaria o menos a 3 con educación superior.

Prueba 6: leer libros y libros en casa. H_0: leer libros es independiente de haber tenido libros en casa durante la infancia; H_1: están asociados. Todas las frecuencias esperadas superan 5 (mínimo 1929.3). El estadístico $\chi^2 = 789.0$, dividido entre el efecto de diseño (1.32), da $\chi^2_{RS} = 598.4$, mayor que el valor crítico $\chi^2_{0.04,\,1} = 4.22$ (valor $p < 0.001$): se rechaza H_0. Leyó libros 53.2% de quienes tuvieron libros en casa, frente a 26.0% de quienes no los tuvieron. La Tabla 4 resume las seis pruebas y la Figura 12 (Anexo C) ubica cada estadístico respecto a su zona de rechazo.

Tabla 4: Resumen de las pruebas de hipótesis ($\alpha = 0.04$).

Prueba	H_1	Distribución	Valor crítico	Estadístico	Valor p	Decisión
1. No lectura, 2024 vs. 2019	$p_{2024} > p_{2019}$	Normal Z	1.75	3.16	< 0.001	Rechazar H_0
2. Lectura de libros, 2024 vs. 2019	$p_{2024} \neq p_{2019}$	Normal Z	± 2.05	-0.20	0.8409	No rechazar H_0
3. Lectura de periódicos, 2024 vs. 2019	$p_{2024} < p_{2019}$	Normal Z	-1.75	-10.06	< 0.001	Rechazar H_0
4. ANOVA: log(1 + libros) por escolaridad	Al menos una media difiere	$F(3, 4{,}860)$	2.77	92.6	< 0.001	Rechazar H_0
5. Kruskal–Wallis: libros por escolaridad	Al menos una mediana difiere	$\chi^2(3)$	8.31	349.2	< 0.001	Rechazar H_0
6. Libros leídos × libros en casa	Están asociados	$\chi^2(1)$, Rao–Scott	4.22	598.4	< 0.001	Rechazar H_0

3.4 Arquetipos de lector

Tabla 5: Características de los seis arquetipos de lector (muestra 2019–2024). Arriba de la línea, variables de agrupamiento; abajo, caracterización (descriptiva).

	No lectores	Periódicos	Internet	Impresos	Libros digitales	Historietas
Personas (% de la muestra)	3,754 (32.1)	1,587 (13.6)	2,799 (24.0)	2,017 (17.3)	937 (8.0)	591 (5.1)
Leyó libros (%)	1.1	34.8	50.8	74.7	100.0	69.0
Libros al año (media)	0.0	1.2	1.6	2.0	4.9	3.5
Leyó revistas (%)	3.5	37.9	32.4	39.6	38.3	54.1
Leyó periódicos (%)	3.9	100.0	15.0	14.5	28.7	38.2
Lee internet (%)	0.2	29.4	100.0	0.0	75.2	69.5
Lee historietas (%)	0.0	0.0	0.0	0.0	0.0	100.0
Lee libros digitales (%)	0.0	0.3	0.0	0.0	100.0	21.7
Acostumbra leer (%)	7.3	77.1	75.5	90.9	95.4	87.8
Minutos por sesión (mediana)	0	30	30	30	45	30
Edad media (años)	49.2	48.6	38.6	50.9	37.8	34.7
Educación superior (%)	12.3	32.0	42.6	25.9	65.1	37.4
Libros en casa en la infancia (%)	37.7	66.4	73.9	58.3	84.3	76.0
Peso ponderado 2019 → 2024 (%)	28.6 → 33.0	19.2 → 9.4	25.4 → 27.3	15.4 → 16.1	6.2 → 9.6	5.2 → 4.6

Los arquetipos. La Tabla 5 los describe. Los **no lectores** (33.0% de la población en 2024) casi no leen nada. Los otros cinco se distinguen por el material que los define: todos los **lectores de periódicos** leen periódicos; todos los **lectores de internet** leen páginas de internet, y la mitad también libros; los **lectores de impresos** no leen en internet, pero tres de cada cuatro leen libros; los **lectores de libros digitales** son los más intensivos (4.9 libros al año), y los **lectores de historietas** combinan más materiales que nadie. De forma descriptiva, entre 2019 y 2024 el peso de los lectores de periódicos bajó de 19.2% a 9.4%, mientras que crecieron los no lectores y los lectores de libros digitales, en línea con lo que las pruebas 1 y 3 confirmaron para los indicadores.

4. Discusión y conclusiones

4.1 Respuesta a la pregunta de investigación

Entre 2019 y 2024, con 96% de confianza, la no lectura en la población urbana alfabeta aumentó entre 1.8 y 8.6 puntos (prueba 1), sobre todo entre personas con secundaria y media superior, y la lectura de periódicos cayó entre 12.9 y 19.4 puntos (prueba 3), mientras que no hay evidencia de cambio en la lectura de libros ni de internet (prueba 2). La cantidad de libros que leen los lectores crece con la escolaridad (pruebas 4 y 5) y leer libros se asocia con haber tenido libros en casa (prueba 6). La exploración con *k-means* propone seis arquetipos que se distinguen por *qué* leen más que por *quiénes* son, y cuyo peso se movió de los periódicos hacia los no lectores y los libros digitales. Así, los datos indican que el fomento de la lectura que motivó a MOLEC no ha frenado la no lectura, y sugieren dirigir las acciones según los gustos y canales de cada arquetipo, con atención especial al hogar.

Qué sí y qué no se pudo responder. Se pudo responder cómo cambió la lectura en la población (qué indicadores cambiaron y cuánto), en qué niveles de escolaridad aumentó la no lectura, cómo se relacionan la escolaridad y el hogar con la lectura, y qué arquetipos de lector existen y cuánto pesa cada uno. No fue posible saber *por qué* cambió la lectura ni si las personas que dejaron de leer periódicos pasaron a leer en internet o dejaron de leer, porque cada año se entrevista a personas distintas. Tampoco se probó

estadísticamente si el peso de los arquetipos cambió, porque se definieron con los mismos datos.

4.2 Recomendaciones: estrategia de fomento por arquetipo

Segmentar por gustos de lectura, no solo por demografía. Los arquetipos se relacionan con la edad y la escolaridad, pero no se reducen a ellas (Figura 3). La V de Cramér, que mide la fuerza de la asociación entre 0 y 1, es de 0.20 con la edad y de 0.24 con la escolaridad: una asociación moderada. Si se asignara a cada persona el arquetipo más común de su combinación de edad y escolaridad, se acertaría solo en 39.9% de los casos, apenas más que el 32.1% que se logra sin usar la demografía; y en ninguna de esas combinaciones el arquetipo más común reúne a más del 57.2% de las personas. Por ejemplo, entre los 18 y 29 años conviven lectores de internet (36.3%), no lectores (20.3%) y lectores de libros digitales (14.4%). Una campaña dirigida "a los jóvenes" o "a las personas con secundaria" mezclaría públicos que leen cosas distintas en canales distintos. Por eso la estrategia que proponemos parte de **qué y cómo lee cada persona** (el arquetipo) y usa la demografía solo para localizar a esos públicos.

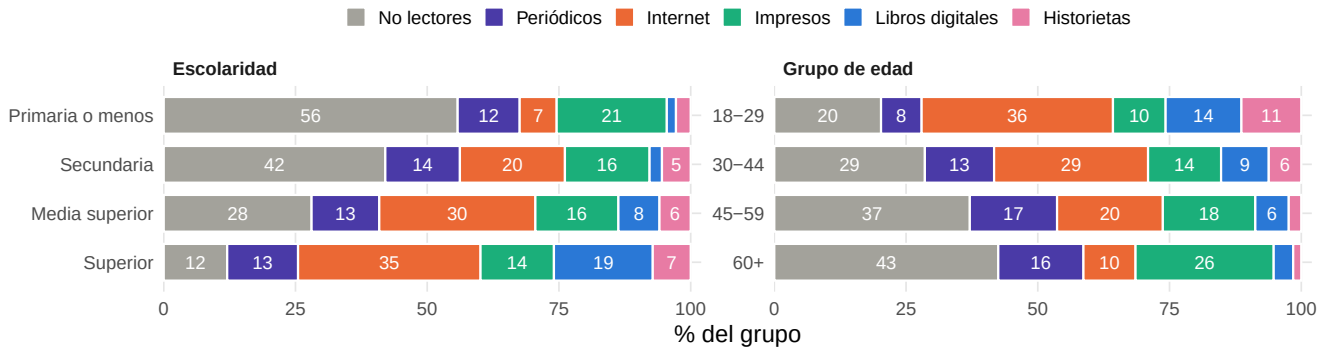


Figura 3: Composición ponderada de los arquetipos de lector dentro de cada grupo de edad y nivel de escolaridad, 2019–2024 (% por fila).

La Tabla 6 traduce los resultados en una propuesta por arquetipo. Las acciones son recomendaciones derivadas del análisis, no resultados probados; su efecto tendría que evaluarse con nuevas mediciones.

Dos líneas son transversales. Primero, **el hogar**: leer libros se asocia con haber tenido libros en casa durante la infancia (prueba 6), incluso dentro de cada nivel de escolaridad (sección 3.1), por lo que llevar libros a los hogares con niños atiende a los no lectores de hoy y a los posibles lectores de mañana. Segundo, **la medición**: el peso de cada arquetipo puede calcularse cada año con MOLEC y servir como indicador para evaluar si las acciones funcionan, más allá del porcentaje general de lectores. Iniciativas existentes como Pasión por la lectura del Tecnológico de Monterrey (s. f.) ya ofrecen piezas de esta estrategia: sus cápsulas literarias de un minuto y su colección de libros digitales se ajustan a los lectores de internet, y sus círculos de lectura, a los lectores de libros digitales y de impresos.

Consecuencias de no atender estas recomendaciones. Si el fomento sigue dirigiéndose a promedios o a grupos demográficos, mezclará públicos con gustos y canales distintos y seguirá sin llegar a quienes no leen, cuyo peso en la población pasó de 28.6% a 33.0% entre 2019 y 2024. Como la lectura frecuente y la comprensión lectora se refuerzan mutuamente (Mol y Bus, 2011), dejar crecer la no lectura, sobre todo en los hogares con niños, puede trasladar el rezago a la siguiente generación. Y sin medir el peso de cada arquetipo, no habrá forma de saber si las acciones funcionan.

Tabla 6: Propuesta de estrategia de fomento de la lectura por arquetipo.

Arquetipo	Peso 2024 (tendencia)	Qué los define	Estrategia propuesta
No lectores	33.0% (crece)	Casi no leen; mayores, menos escolaridad, pocos libros en casa en la infancia	Lectura de entrada según sus intereses (textos breves y prácticos, audio) y programas de libros en casa para familias con niños, para cortar la transmisión entre generaciones
Lectores de periódicos	9.4% (cae)	Prensa; mayores; el grupo que más se redujo	Acompañar la transición: acceso a prensa digital y crónica, y círculos de lectura de actualidad en bibliotecas
Lectores de internet	27.3% (estable)	Páginas de internet; jóvenes; la mitad no lee libros	Puente de la pantalla al libro: fragmentos y recomendaciones en las plataformas que ya leen, préstamo de libros digitales y no ficción de sus temas
Lectores de impresos	16.1% (estable)	Libros y revistas en papel, sin internet; los de mayor edad	Mantener el acceso físico: bibliotecas, ferias y libro usado; no depender de campañas digitales
Lectores de libros digitales	9.6% (crece)	Libros digitales, los más intensivos; jóvenes con más escolaridad	Convertirlos en mediadores: clubes, reseñas y recomendaciones entre pares
Lectores de historietas	4.6% (estable)	Historietas y muchos otros materiales; los más jóvenes	Usar la novela gráfica como puerta de entrada a la narrativa en escuelas y bibliotecas

4.3 Limitaciones

Las estimaciones incorporan el factor de expansión y el efecto de diseño de la ponderación, pero no los conglomerados de MOLEC, por lo que los intervalos son algo optimistas. Los arquetipos son exploratorios y no se sometieron a inferencia. Al ser datos observacionales y cortes transversales, los resultados son asociaciones y cambios en la población, no causas ni trayectorias individuales.

Supuestos de los análisis. Las pruebas e intervalos de proporciones usan la aproximación normal, justificada por el teorema del límite central ($n\hat{p}$ y $n(1-\hat{p})$ mayores que 5 con el tamaño efectivo). El ANOVA supone normalidad, que la prueba de Shapiro–Wilk rechaza; se sostuvo en el teorema del límite central y se confirmó con Welch y Kruskal–Wallis. El intervalo del cociente de varianzas también supone normalidad y es sensible a su ausencia, por lo que se contrastó con la prueba de Levene. La corrección de Rao–Scott es de primer orden. Para *k-means*, los valores "no aplica" se fijaron en 0, lo que hace que los no lectores formen su propio grupo. Además, MOLEC se basa en autorreporte: la lectura registrada es la que cada persona declara.

4.4 Nuevas preguntas de investigación

- ¿Las personas que dejaron de leer periódicos pasaron a leer en internet o dejaron de leer? Responderlo requeriría datos de panel o de cohortes.
- ¿Por qué la no lectura aumentó más entre las personas con secundaria y media superior?
- ¿El crecimiento de la lectura de libros digitales a partir de 2021 es un efecto duradero de la pandemia?
- ¿Qué tipo de libros leen y con qué motivo los lectores de impresos, el arquetipo de mayor edad?
- ¿Los arquetipos se reproducen con la nueva serie de MOLEC de 2025, que incluye a personas de 12 a 17 años y a todo el país?
- Con el diseño muestral completo (estratos y conglomerados), ¿se mantienen las conclusiones?

4.5 Recomendaciones para nosotros

En retrospectiva, nos recomendaríamos: (1) revisar el diccionario y los códigos especiales antes de limpiar los datos, pues eliminar registros con `na.omit()` sesgó la base de la primera etapa; (2) definir las preguntas e indicadores de la inferencia antes de explorar, en lugar de probar diferencias entre grupos formados con los mismos datos; (3) incorporar el diseño muestral desde el inicio, y (4) revisar los supuestos antes de elegir cada prueba y considerar desde el principio pruebas no paramétricas cuando los datos son muy asimétricos.

Referencias

Delgado, P., Vargas, C., Ackerman, R., & Salmerón, L. (2018). Don't throw away your printed books: A meta-analysis on the effects of reading media on reading comprehension. *Educational Research Review, 25*, 23–38. https://doi.org/10.1016/j.edurev.2018.09.003

Fernández Martínez, M. A. (2025, 30 de septiembre). *Leer menos hoy, rezagos del mañana* [Video]. Cursos de Estadística, Tecnológico de Monterrey.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Instituto Nacional de Estadística y Geografía. (2019–2025). *Módulo sobre Lectura (MOLEC)* [Conjunto de datos: microdatos, diccionarios de datos y cuestionario, levantamientos 2019 a 2025]. https://www.inegi.org.mx/programas/molec/

Instituto Nacional de Estadística y Geografía. (2024). *Módulo sobre Lectura (MOLEC) 2024* (Comunicado de prensa núm. 235/24). https://www.inegi.org.mx/contenidos/saladeprensa/boletines/2024/molec/molec2024.pdf

Instituto Nacional de Estadística y Geografía. (2025). *Módulo sobre Lectura (MOLEC) 2025* (Comunicado de prensa núm. 143/25). https://www.inegi.org.mx/contenidos/saladeprensa/boletines/2025/molec/molec2025_CP.pdf

Kish, L. (1965). *Survey sampling*. John Wiley & Sons.

Mol, S. E., & Bus, A. G. (2011). To read or not to read: A meta-analysis of print exposure from infancy to early adulthood. *Psychological Bulletin, 137*(2), 267–296. https://doi.org/10.1037/a0021890

OECD. (2026). *PISA 2025 results (Volume I): Country notes: Mexico*. OECD Publishing. https://www.oecd.org/en/publications/pisa-2025-results-volume-i-country-notes_2d4ff9ea-en/mexico_85702d30-en.html

Rao, J. N. K., & Scott, A. J. (1984). On chi-squared tests for multiway contingency tables with cell proportions estimated from survey data. *The Annals of Statistics, 12*(1), 46–60. https://doi.org/10.1214/aos/1176346391

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Tecnológico de Monterrey. (s. f.). *Actividades de Pasión por la lectura*. Recuperado el 24 de octubre de 2026, de https://tec.mx/es/pasion-por-la-lectura/actividades-de-pasion-por-la-lectura

UNESCO. (2021, 25 de marzo). *100 million more children under the minimum reading proficiency level due to COVID-19: UNESCO convenes world education ministers*. https://www.unesco.org/en/articles/100-million-more-children-under-minimum-reading-proficiency-level-due-covid-19-unesco-convenes-world

Anexo A. Variables de la base preparada

Tabla 7: Variables de la base preparada: las 25 seleccionadas en la Etapa 1 (arriba de la línea) y las 7 derivadas en la Etapa 2 (abajo). Faltantes sobre 11,685 registros; en minutos y lib_digital son personas a quienes la pregunta no aplica. La base de perfiles agrega la columna perfil.

Variable	Descripción (pregunta de MOLEC)	Tipo	Valores o categorías	Faltantes	Papel
anio	Año del levantamiento	Ordinal	2019–2024	0	Tendencia
factor	Factor de expansión	Numérica	personas que representa	0	Ponderación
acostumbra	p2. Acostumbra leer	Nominal (binaria)	1 Sí, 0 No	0	Agrupamiento
lee_libros	p3_1. Leyó libros en los últimos 12 meses	Nominal (binaria)	1 Sí, 0 No	0	Agrupamiento
lee_revistas	p3_2. Leyó revistas en los últimos 3 meses	Nominal (binaria)	1 Sí, 0 No	0	Agrupamiento
lee_periodicos	p3_3. Leyó periódicos la semana pasada	Nominal (binaria)	1 Sí, 0 No	0	Agrupamiento
lee_historietas	p3_4. Lee historietas	Nominal (binaria)	1 Sí, 0 No	0	Agrupamiento
lee_internet	p3_5. Lee páginas de internet, foros o blogs (sin redes sociales)	Nominal (binaria)	1 Sí, 0 No	0	Agrupamiento
n_libros	p4. Libros leídos en 12 meses	Numérica discreta	libros, 0–99 (0 = no leyó)	0	Agrupamiento
n_revistas	p10. Revistas leídas en 3 meses	Numérica discreta	revistas, 0–99	0	Agrupamiento
n_periodicos	p16. Periódicos leídos la semana pasada	Numérica discreta	periódicos, 0–80	0	Agrupamiento
minutos	p26. Minutos continuos que lee	Numérica	minutos, 1–480	3,442 (29.5%)	Agrupamiento
lib_digital	p8_1. Leyó libros en formato digital	Nominal (binaria)	1 Sí, 0 No	6,817 (58.3%)	Agrupamiento
sexo	Sexo	Nominal	Hombre, Mujer	0	Validación
edad	Edad	Numérica discreta	años, 18–97	0	Validación
nivel	Nivel de instrucción	Ordinal	0 Ninguno, 1 Preescolar, 2 Primaria, 3 Secundaria, 4 Bachillerato, 5 Normal, 6 Carrera técnica, 7 Profesional, 8 Maestría, 9 Doctorado	24 (0.2%)	Validación
entidad	Entidad federativa de la ciudad	Nominal	01–32	0	Validación
inf_bibliotecas	p34_1. Infancia: lo llevaban a bibliotecas o librerías	Nominal (binaria)	1 Sí, 0 No	234 (2.0%)	Validación
inf_veia_leer	p34_2. Infancia: veía leer a sus padres o tutores	Nominal (binaria)	1 Sí, 0 No	185 (1.6%)	Validación
inf_le_leian	p34_3. Infancia: sus padres o tutores le leían	Nominal (binaria)	1 Sí, 0 No	231 (2.0%)	Validación
inf_libros_casa	p34_4. Infancia: había libros (no de texto) en casa	Nominal (binaria)	1 Sí, 0 No	357 (3.1%)	Validación
esc_pedian_leer	p36_1. Primaria: le pedían leer otros libros	Nominal (binaria)	1 Sí, 0 No	567 (4.9%)	Validación
esc_comentar	p36_2. Primaria: le pedían comentar lo leído	Nominal (binaria)	1 Sí, 0 No	383 (3.3%)	Validación
esc_motivaban	p36_3. Primaria: lo motivaban a leer otros libros	Nominal (binaria)	1 Sí, 0 No	487 (4.2%)	Validación
esc_bibliotecas	p36_4. Primaria: lo animaban a visitar bibliotecas	Nominal (binaria)	1 Sí, 0 No	509 (4.4%)	Validación
tipo_lector	Derivada de mat_lec (INEGI): materiales leídos	Nominal	No lee, Solo otros materiales, Solo libros, Libros y otros	0	Exploración
n_materiales	Derivada de p3_1–p3_5: número de materiales leídos	Numérica discreta	0–5	0	Exploración
grupo_edad	Derivada de edad	Ordinal	18-29, 30-44, 45-59, 60+	0	Validación
escolaridad	Derivada de nivel	Ordinal	Primaria o menos (0–2), Secundaria (3), Media superior (4–6), Superior (7–9)	24 (0.2%)	Validación

Tabla 7: Variables de la base preparada: las 25 seleccionadas en la Etapa 1 (arriba de la línea) y las 7 derivadas en la Etapa 2 (abajo). Faltantes sobre 11,685 registros; en minutos y lib_digital son personas a quienes la pregunta no aplica. La base de perfiles agrega la columna perfil. (continuación)

Variable	Descripción (pregunta de MOLEC)	Tipo	Valores o categorías	Faltantes	Papel
ind_hogar	Derivada de p34_1–p34_4: estímulos a la lectura en el hogar	Numérica discreta	0–4	658 (5.6%)	Validación
ind_escuela	Derivada de p36_1–p36_4: estímulos a la lectura en la primaria	Numérica discreta	0–4	981 (8.4%)	Validación
particion	Derivada: subconjunto para el modelado	Nominal	entrenamiento, validacion, prueba	0	Modelado

La Tabla 8 detalla los códigos especiales que se revisaron en el diccionario, su significado y la decisión que se tomó con cada uno.

Tabla 8: Códigos especiales revisados en la población alfabeta y decisión tomada.

Código encontrado	Significado (diccionario)	Decisión	Registros
p1 = 2	No sabe leer: el resto del módulo no se aplica	Se excluye de la población	281
nivel = 99	Escolaridad no especificada	NA; se conserva el registro	24
p4, p10, p16 = 0	Pase: no leyó ese material	Cero válido (0 libros, revistas. . .)	6,817 / 8,566 / 8,744
p26 = 0	Pase: no lee ningún material	NA (no aplica) en minutos	3,442
p8_1 = 0	Pase: no leyó libros	NA (no aplica) en lib_digital	6,817
p34_*, p36_* = 3	No recuerda	NA	185–445
p36_* = 0	Pase: no asistió a la primaria (p35 = 2)	NA (no aplica)	122
p4, p10 = 99	Dentro del rango 01–99 de su año	Valor válido, atípico; se conserva	2

Anexo B. Resultados descriptivos complementarios (Etapa 2)

Este anexo reúne las tablas y gráficas de la Etapa 2 que respaldan la sección 3.1. La Tabla 9 da las frecuencias de las variables categóricas y la Figura 5, las distribuciones de la edad, los libros y los minutos: la edad es casi simétrica, mientras que libros y minutos se concentran en valores bajos con una cola larga a la derecha (y los minutos, en valores redondos como 30 y 60).

Tabla 9: Distribución de frecuencias de las variables categóricas, 2019–2024 (n de la muestra y % ponderado; % acumulado solo en las ordinales).

Variable	Categoría	n	% pond.	% acum.	Variable	Categoría	n	% pond.	% acum.
Tipo de lector	No lee	3,442	28.6		Grupo de edad	18-29	2,414	26.5	26.5
	Solo otros materiales	3,375	29.4			30-44	3,580	28.3	54.8
	Solo libros	1,205	9.7			45-59	3,186	26.9	81.7
	Libros y otros	3,663	32.4			60+	2,505	18.3	100.0
Escolaridad	Primaria o menos	2,021	16.1	16.1	Sexo	Hombre	5,150	46.9	
	Secundaria	2,863	24.4	40.5		Mujer	6,535	53.1	
	Media superior	3,266	29.4	70.0	Estímulos en la primaria	0	1,475	12.9	12.9
	Superior	3,511	30.0	100.0		1	1,151	10.5	23.4
Estímulos en el hogar	0	3,201	27.7	27.7		2	1,554	14.3	37.7
	1	2,006	18.3	46.0		3	1,770	16.5	54.2
	2	1,837	17.1	63.1		4	4,754	45.8	100.0
	3	2,044	18.5	81.6					
	4	1,939	18.4	100.0					

La Figura 4 muestra la distribución del tipo de lector dentro de cada nivel de escolaridad y según los estímulos a la lectura en el hogar: la no lectura baja de forma marcada conforme aumentan ambos.

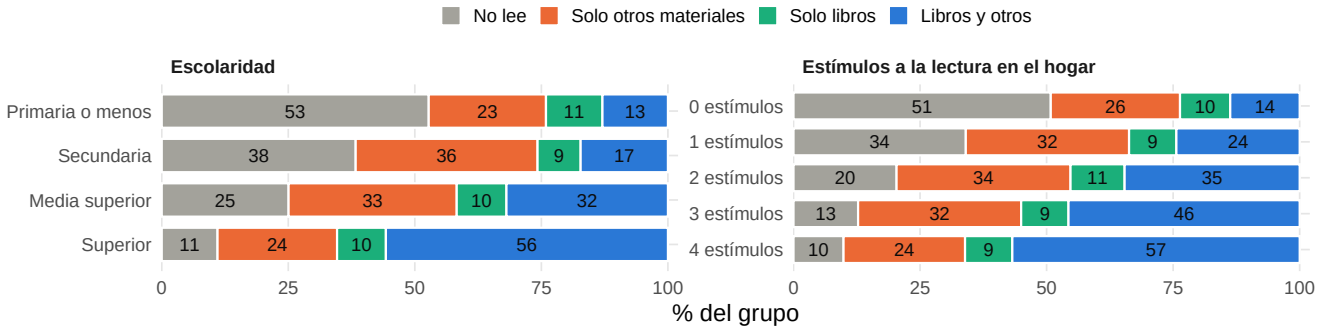


Figura 4: Distribución ponderada del tipo de lector dentro de cada nivel de escolaridad y según el número de estímulos a la lectura en el hogar durante la infancia (% por fila).



Figura 5: Distribución de la edad, de los libros leídos en 12 meses (lectores de libros; se omiten valores mayores a 30) y de los minutos de lectura (lectores; se omiten valores mayores a 180). Línea continua: mediana; discontinua: media.

La Figura 6 y la Tabla 10 muestran la evolución por año: la no lectura alcanzó su máximo en 2023, quienes leen solo libros casi se duplicaron, la mediana fue de 2 libros y 30 minutos en todos los años y la lectura de libros digitales subió en 2021.

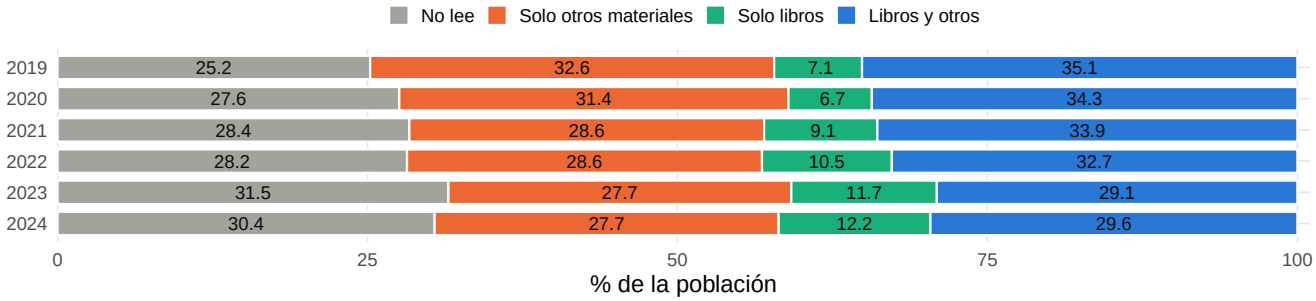


Figura 6: Distribución ponderada del tipo de lector por año (%).

Tabla 10: Indicadores complementarios de lectura por año (% y media de materiales ponderados; conteos sobre la muestra).

	2019	2020	2021	2022	2023	2024
Materiales leídos (media)	1.6	1.5	1.4	1.4	1.3	1.3
Libros: mediana (Q1–Q3)*	2 (1–4)	2 (1–4)	2 (1–4)	2 (1–4)	2 (1–4)	2 (1–3)
Libros: media*	3.3	3.5	3.8	3.9	3.5	3.2
Libro digital (%)*	16.4	17.0	27.1	27.6	28.5	26.0
Minutos: mediana (Q1–Q3)	30 (20–50)	30 (20–60)	30 (20–60)	30 (20–60)	30 (20–60)	30 (20–60)

* Solo quienes leyeron libros.

La Figura 7 y la Tabla 11 comparan los libros leídos por grupo: la mediana sube con la escolaridad y es mayor entre los 18 y 29 años, y en todos los grupos la media supera a la mediana. Por sexo, la mediana es de 2 libros en ambos grupos, aunque las mujeres leen libros en mayor proporción y los hombres leen más periódicos (Tabla 12).

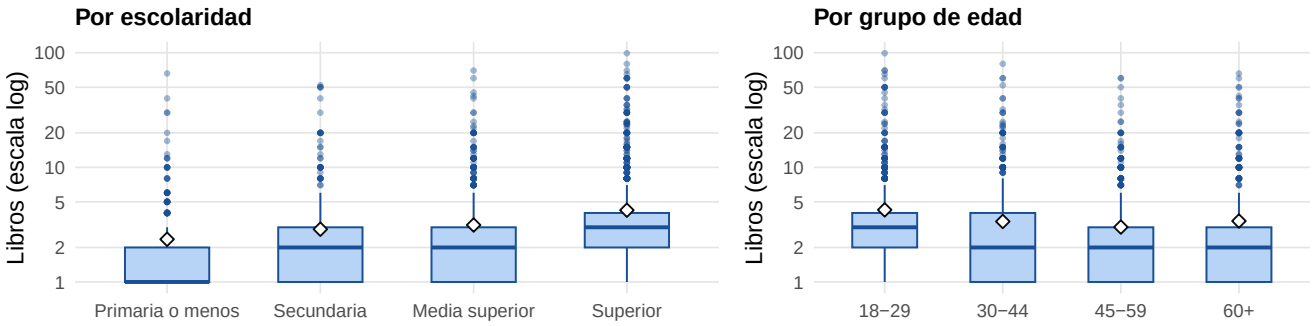


Figura 7: Libros leídos en 12 meses por escolaridad y por grupo de edad, solo lectores de libros (escala logarítmica). El rombo indica la media.

Tabla 11: Libros leídos en 12 meses por grupo, solo lectores de libros (muestra sin ponderar).

Grupo	n	Mediana	Q1	Q3	Media	DE	Máx.
Escolaridad							
Primaria o menos	500	1	1	2	2.4	4.3	66
Secundaria	762	2	1	3	2.9	4.6	52
Media superior	1,336	2	1	3	3.1	4.3	70
Superior	2,266	3	2	4	4.2	6.3	99
Grupo de edad							
18-29	1,290	3	2	4	4.3	6.6	99
30-44	1,459	2	1	4	3.4	4.8	80
45-59	1,163	2	1	3	3.0	4.2	60
60+	956	2	1	3	3.4	5.7	66
Sexo							
Hombre	2,060	2	1	4	3.7	5.4	99
Mujer	2,808	2	1	4	3.4	5.4	80

Tabla 12: Distribución ponderada del tipo de lector por grupo de edad y sexo (% por fila).

Grupo	No lee	Solo otros materiales	Solo libros	Libros y otros
Grupo de edad				
18-29	17.8	28.1	7.6	46.5
30-44	26.0	33.9	8.2	31.9
45-59	34.3	30.0	9.9	25.7
60+	39.9	23.2	14.5	22.4
Sexo				
Hombre	26.1	33.9	7.6	32.4
Mujer	30.8	25.3	11.5	32.3

La Figura 8 y la Tabla 13 muestran que la no lectura aumentó dentro de cada nivel de escolaridad y sobre todo entre los 45 y 59 años (de 26.9% a 35.1%), aunque la proporción de la población con educación superior creció.

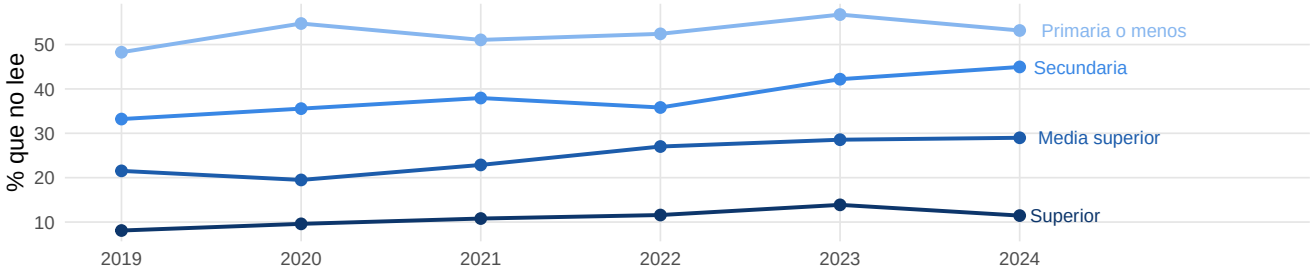


Figura 8: Porcentaje ponderado que no leyó ningún material, por año y nivel de escolaridad.

Tabla 13: Porcentaje ponderado que no lee por grupo de edad (columnas 2–5) y composición ponderada por escolaridad (columnas 6–9), por año.

	No lee (%) por grupo de edad				Población por escolaridad (%)			
Año	18-29	30-44	45-59	60+	Primaria o menos	Secundaria	Media superior	Superior
2019	15.3	26.6	26.9	37.9	17.2	25.2	28.7	28.9
2020	17.6	24.0	34.3	38.6	18.7	25.3	28.4	27.6
2021	17.5	25.6	36.4	38.2	17.2	27.5	26.3	29.0
2022	20.1	24.5	33.5	37.7	15.1	23.2	29.9	31.8
2023	18.6	27.9	39.2	43.5	15.3	22.4	31.4	30.9
2024	17.9	27.3	35.1	42.2	13.5	23.4	31.4	31.6

La Tabla 14 describe los ocho antecedentes por separado (el más común en casa fue tener libros, 61.0%, y en la primaria, comentar lo leído, 79.5%), y la Figura 9, la no lectura por entidad; como cada ciudad tiene entre 187 y 1,316 registros, esas diferencias son solo descriptivas.

Tabla 14: Porcentaje ponderado que reporta cada antecedente de lectura en casa (infancia) y en la escuela primaria.

Antecedente	Variable	n válidos	% Sí (ponderado)
En casa durante la infancia (p34)			
Lo llevaban a bibliotecas o librerías	inf_bibliotecas	11,451	31.2
Veía leer a sus padres o tutores	inf_veia_leer	11,500	52.4
Sus padres o tutores le leían	inf_le_leian	11,454	36.4
Había libros (no de texto) en casa	inf_libros_casa	11,328	61.0
En la escuela primaria (p36)			
Le pedían leer otros libros	esc_pedian_leer	11,118	61.9
Le pedían comentar lo leído	esc_comentar	11,302	79.5
Lo motivaban a leer otros libros	esc_motivaban	11,198	69.2
Lo animaban a visitar bibliotecas	esc_bibliotecas	11,176	59.8

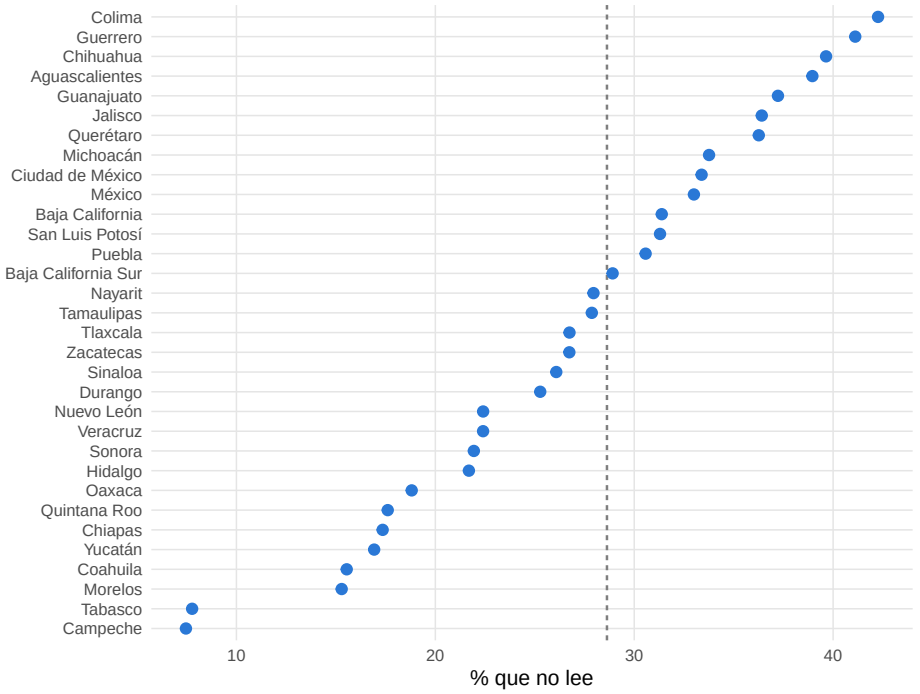


Figura 9: Porcentaje ponderado que no leyó ningún material por entidad federativa (ciudad de 100 mil habitantes o más de cada entidad), 2019–2024. La línea discontinua marca el total.

La Tabla 15 presenta las correlaciones de Spearman entre quienes leen algún material y la Figura 10, la relación entre libros y minutos: es creciente pero con mucha dispersión.

Tabla 15: Correlaciones de Spearman entre variables de lectura y de validación (personas que leen algún material).

	Libros	Revistas	Periódicos	Minutos	Internet	Edad	Escolaridad	Est. hogar
Libros	1.00	0.01	-0.12	0.45	0.11	-0.09	0.30	0.22
Revistas	0.01	1.00	0.07	0.07	0.04	0.00	0.07	0.12
Periódicos	-0.12	0.07	1.00	-0.04	-0.15	0.15	-0.03	0.01
Minutos	0.45	0.07	-0.04	1.00	0.12	-0.01	0.25	0.19
Internet	0.11	0.04	-0.15	0.12	1.00	-0.34	0.30	0.21
Edad	-0.09	0.00	0.15	-0.01	-0.34	1.00	-0.19	-0.22
Escolaridad	0.30	0.07	-0.03	0.25	0.30	-0.19	1.00	0.34
Est. hogar	0.22	0.12	0.01	0.19	0.21	-0.22	0.34	1.00

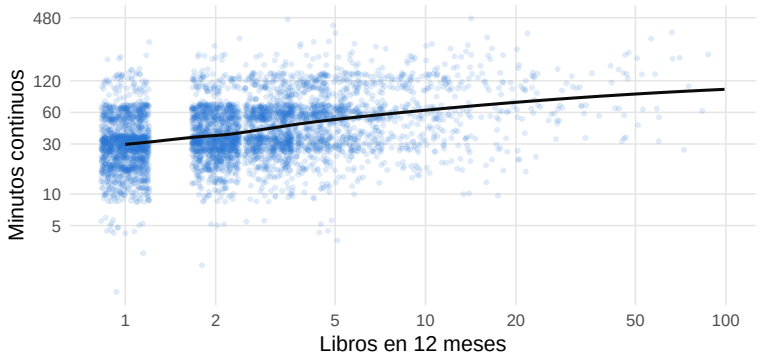


Figura 10: Libros leídos frente a minutos de lectura, lectores de libros (ejes en escala logarítmica; puntos con desplazamiento aleatorio). La línea es una curva suavizada (loess).

Anexo C. Detalles de los supuestos y del agrupamiento

Aproximación normal de las proporciones. La Tabla 16 muestra, para cada indicador y año, el tamaño efectivo y los valores $n_{ef}\hat{p}$ y $n_{ef}(1-\hat{p})$; todos superan con amplitud el mínimo de 5, por lo que el teorema del límite central justifica usar la distribución normal en los intervalos y en las pruebas Z.

Tabla 16: Condiciones para la aproximación normal de las proporciones (con el tamaño efectivo de Kish).

Indicador	Año	n efectivo	n · p	n · (1 - p)	¿Cumple?
No leyó ningún material	2019	1,488	375.3	1112.9	Sí
No leyó ningún material	2024	1,488	452.4	1035.2	Sí
Leyó libros	2019	1,488	628.1	860.1	Sí
Leyó libros	2024	1,488	622.4	865.2	Sí
Leyó periódicos	2019	1,488	506.2	982.1	Sí
Leyó periódicos	2024	1,488	265.4	1222.2	Sí
Lee internet	2019	1,488	606.5	881.7	Sí
Lee internet	2024	1,488	586.8	900.8	Sí

Normalidad en el ANOVA. La Tabla 17 presenta la prueba de Shapiro–Wilk de $\log(1 + \text{libros})$ en cada nivel de escolaridad (H_0: los datos provienen de una distribución normal). Rechaza la normalidad en los cuatro niveles, lo que es esperable con un conteo discreto y muestras grandes, en las que la prueba detecta desviaciones pequeñas. La gráfica Q-Q de los residuos (Figura 11) muestra escalones por los valores enteros y una cola derecha más larga, pero la asimetría es mucho menor que la del conteo original. Como cada nivel tiene al menos 500 lectores, por el teorema del límite central las medias muestrales son aproximadamente normales y el ANOVA es válido; además, el resultado se confirmó con la prueba de Kruskal–Wallis, que no requiere normalidad y compara medianas (Tabla 18).

Tabla 17: Prueba de normalidad de Shapiro–Wilk por nivel de escolaridad (lectores de libros).

Escolaridad	n	Sesgo de libros	Sesgo de log(1 + libros)	W de Shapiro–Wilk	Valor p	Resultado
Primaria o menos	500	9.29	2.35	0.68	< 0.001	Se rechaza normalidad
Secundaria	762	7.21	1.83	0.78	< 0.001	Se rechaza normalidad
Media superior	1,336	7.43	1.46	0.84	< 0.001	Se rechaza normalidad
Superior	2,266	6.76	1.33	0.88	< 0.001	Se rechaza normalidad

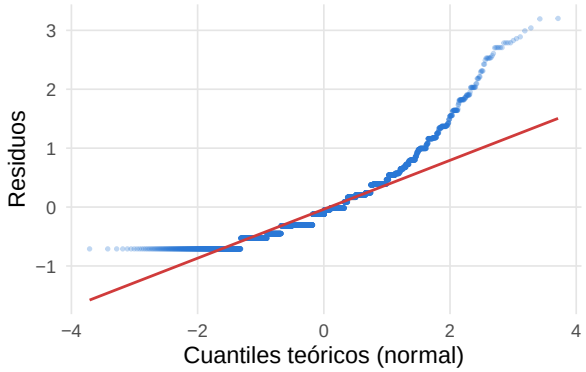


Figura 11: Gráfica Q-Q de los residuos del ANOVA de log(1 + libros) por escolaridad.

Tabla 18: Pruebas de supuestos y de robustez del ANOVA de log(1 + libros) por escolaridad.

Prueba	Qué revisa	Estadístico	Valor p	Resultado
Levene	Igualdad de varianzas (robusta a la no normalidad)	$F = 15.9$	< 0.001	Varianzas distintas
Bartlett	Igualdad de varianzas (supone normalidad)	$K^2 = 45.6$	< 0.001	Varianzas distintas
ANOVA de Welch	Medias iguales sin suponer varianzas iguales	$F = 98.1$	< 0.001	Medias distintas
Kruskal–Wallis	Medianas iguales (no paramétrica)	$H = 349.2$	< 0.001	Medianas distintas

Zonas de rechazo. La Figura 12 muestra, para las pruebas 1, 2, 4 y 6, la distribución muestral, la zona de rechazo a partir del valor crítico y el estadístico obtenido; en las pruebas 1, 4 y 6 el estadístico cae dentro de la zona de rechazo, y en la prueba 2, fuera de ella.

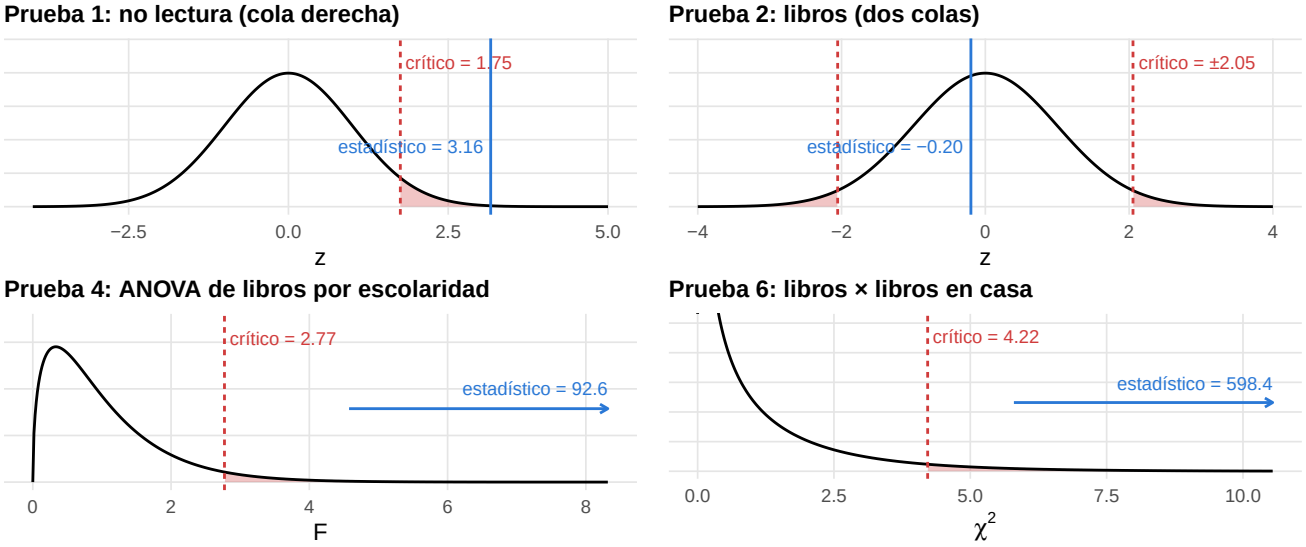


Figura 12: Distribución muestral, zona de rechazo (rojo, a partir del valor crítico) y estadístico de prueba (azul) de las pruebas 1, 2, 4 y 6. Cuando el estadístico queda fuera de la escala, una flecha indica su valor.

Agrupamiento. La Tabla 19 da, para cada número de grupos, la suma de cuadrados dentro de los grupos en el entrenamiento (que baja de forma gradual, sin un "codo" claro), la silueta y la estabilidad en la validación; la Figura 13 muestra los dos últimos criterios.

Tabla 19: Criterios para elegir el número de arquetipos de k-means.

k	Suma de cuadrados (entrenamiento)	Silueta (validación)	Estabilidad ARI (validación)
2	46,639	0.32	0.99
3	38,136	0.36	0.97
4	31,163	0.39	0.95
5	26,306	0.42	0.95
6	22,870	0.43	0.97
7	20,338	0.43	0.71
8	18,510	0.46	0.75

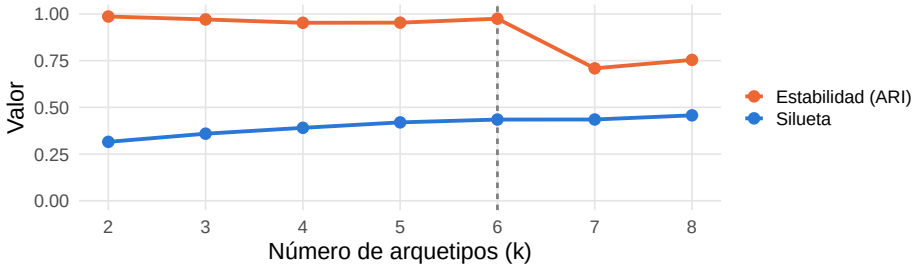


Figura 13: Selección del número de arquetipos con el conjunto de validación: silueta media y estabilidad (ARI) para k = 2 a 8. La línea vertical marca el valor elegido.

Anexo D. Código, datos y declaratoria de uso de inteligencia artificial

Código y datos. Todo el análisis se hizo en R. El repositorio https://github.com/vicho-btw/molec-perfiles-lectores contiene `ReporteFinal.Rmd`, que lee los datos, hace todos los cálculos y genera este reporte (el código está comentado por secciones); las bases `BasePreparada_MOLEC_2019_2024.csv` (11,685 personas, 32 variables) y `BasePerfiles_MOLEC_2019_2024.csv` (la misma base con el arquetipo de cada persona); los microdatos y diccionarios originales de INEGI en la carpeta `datos/`, y un archivo README con las instrucciones para reproducir el análisis.

Declaratoria de uso de inteligencia artificial (Opción B).

1. *Herramienta:* Claude (Anthropic), mediante Claude Code.
2. *Uso realizado:* escritura y depuración del código en R (lectura, limpieza e integración de los datos, cálculos, intervalos, pruebas de hipótesis, gráficas y *k-means*), propuesta de técnicas estadísticas y redacción del texto del reporte.
3. *Secciones donde se utilizó:* todas las secciones del reporte y de los anexos, y el código de `ReporteFinal.Rmd`.
4. *Validación realizada por los estudiantes:* el equipo definió la pregunta de investigación, el enfoque por arquetipos y la estrategia de fomento; incorporó la retroalimentación de las profesoras en cada etapa; revisó las cifras, tablas y gráficas, y verificó las variables y sus códigos contra los diccionarios de INEGI.
5. *Confirmación:* los integrantes del equipo revisamos y verificamos el contenido final entregado y asumimos la responsabilidad sobre él.